




MODELO DE CLASIFICACION DE TEXTO





Bibliotecas Importadas:

1. **tensorflow as tf**: Importa TensorFlow, una biblioteca líder en aprendizaje automático y redes neuronales.
2. **Sequential de keras.models**: Permite la construcción secuencial de modelos de redes neuronales.
3. Capas específicas de la red:
 - **Embedding, LSTM, Dense, Dropout, BatchNormalization de keras.layers**: Define las capas de la red neuronal.
4. Componentes para procesamiento de texto:
 - **Tokenizer y pad_sequences de keras.preprocessing.text**: Facilita la tokenización y secuenciación de textos.
5. **l2 de keras.regularizers**: Implementa la regularización L2 para prevenir el sobreajuste.
6. Callbacks para entrenamiento:
 - **EarlyStopping, ModelCheckpoint de keras.callbacks**: Mejora el control del entrenamiento mediante detención temprana y almacenamiento del mejor modelo.
7. Operaciones matemáticas y manipulación de datos:
 - **numpy as np**: Herramienta fundamental para operaciones matemáticas y manipulación eficiente de datos.
8. Visualización de datos:
 - **matplotlib.pyplot as plt**: Biblioteca para la generación de gráficos y visualización de resultados.

Instalacion de librerias:

`pip install tensorflow keras matplotlib numpy scikit-learn`

```
import tensorflow as tf
from keras.models import Sequential
from keras.layers import Embedding, LSTM, Dense, Dropout, BatchNormalization
from keras.preprocessing.text import Tokenizer
from keras.preprocessing.sequence import pad_sequences
from keras.regularizers import l2
from keras.callbacks import EarlyStopping, ModelCheckpoint
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
import numpy as np
from text_classification_model import TextClassificationModel
from custom_callback import CustomCallback
```



Clase TextClassificationModelImplements:

Constructor (__init__):

- Inicializa la clase con parámetros esenciales: clases, tokenizador y datos de instrucción.

```
def __init__(self, clases=[], tokenizer=None, instruction = []):  
    # Inicialización del modelo y configuración de capas  
    self.clases = clases  
    self.tokenizer = tokenizer  
    self.tokenizer.fit_on_texts(instruction)
```

Método build_model:

- Construye un modelo secuencial de red neuronal con las siguientes capas:
 - Capa de Embedding: Mapea palabras a vectores de alta dimensión.
 - Capas LSTM: Capturan patrones a largo plazo en los datos.
 - Capas Dense: Neuronas completamente conectadas con funciones de activación.
 - Capas de Dropout: Evitan el sobreajuste mediante la eliminación de conexiones aleatorias.
 - Capa de Batch Normalization: Estabiliza y acelera el aprendizaje.

```
def build_model(self):  
    self.model = Sequential([  
        Embedding(input_dim=len(self.tokenizer.word_index) + 1, output_dim=64, input_length=50), #Tamaño del vocabulario(palabras unicas),salida, longitud máx  
        LSTM(units=150, return_sequences=True, kernel_regularizer=l2(0.01)), #capturar patrones a largo plazo en los datos, Aumentar unidades(patrones) y agre  
        Dropout(0.5), # Aumentar Dropout  
        LSTM(units=150, kernel_regularizer=l2(0.01)), # Aumentar unidades y agregar regularización  
        Dense(units=256, activation='relu', kernel_regularizer=l2(0.01)), # cada neurona o unidad está conectada a cada neurona de la capa anterior.  
        BatchNormalization(), #Técnica estabilizar y acelerar el aprendizaje.  
        Dense(units=128, activation='relu', kernel_regularizer=l2(0.01)), # Cambiar activación y agregar regularización  
        Dropout(0.5), # Ajustar Dropout, técnica de regularización que se utiliza para prevenir el sobreajuste en redes neuronales.  
        Dense(units=len(self.clases), activation='softmax')  
    ])  
    self.model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```



Método `train_model`:

- Prepara datos para entrenamiento, realiza tokenización y secuenciación de textos.
- Divide datos en conjuntos de entrenamiento y validación.
- Convierte etiquetas a codificación one-hot.
- Entrena el modelo con callbacks de detención temprana y almacenamiento del mejor modelo.

```
def train_model(self, data_training_class, label_training_class, epochs=20): # Aumentar epochs
    # Preparación de datos para el entrenamiento
    all_texts = []
    all_labels = []

    for i, clase in enumerate(self.clases):
        texts = data_training_class[i]
        labels = [i] * len(texts)
        all_texts.extend(texts)
        all_labels.extend(labels)

    # Tokenización y secuenciación de textos
    if self.tokenizer is None:
        self.tokenizer = Tokenizer(num_words=5000, oov_token="<OOV>")
        self.tokenizer.fit_on_texts(all_texts)
    sequences = self.tokenizer.texts_to_sequences(all_texts)
    padded_sequences = pad_sequences(sequences, maxlen=50, truncating='post')

    # División de datos en conjuntos de entrenamiento y validación
    x_train, x_val, y_train, y_val = train_test_split(padded_sequences, np.array(all_labels), test_size=0.3, random_state=54)

    # Convertir etiquetas a one-hot encoding
    y_train_numeric = np.array(y_train, dtype=int)
    y_train_categorical = tf.keras.utils.to_categorical(y_train_numeric - np.min(y_train_numeric), num_classes=len(self.clases))
    y_val_categorical = tf.keras.utils.to_categorical(y_val - min(y_val), num_classes=len(self.clases))

    # Entrenamiento del modelo
    print("Entrenamiento del Modelo:")
    #custom_callback = CustomCallback()
    #EarlyStopping se detendrá el entrenamiento si la pérdida en el conjunto de validación no mejora después de n épocas (patience=3)
    early_stopping_callback = EarlyStopping(monitor='val_loss', patience=10, restore_best_weights=True)

    # Guarda el mejor modelo durante el entrenamiento
    model_checkpoint_callback = ModelCheckpoint('best_model.h5', save_best_only=True)

    self.history = self.model.fit(
        x_train, y_train_categorical,
        epochs=epochs,
        validation_data=(x_val, y_val_categorical),
        verbose=2,
        callbacks=[model_checkpoint_callback, early_stopping_callback]
    )
```



Método `predict_probability`:

- Preprocesa texto para realizar predicciones de probabilidad.
- Utiliza el modelo entrenado para predecir probabilidades para una clase específica.

```
def predict_probability(self, texto):  
    # Preprocesamiento de texto para predicción  
    sequence = self.tokenizer.texts_to_sequences([texto])  
    padded_sequence = pad_sequences(sequence, maxlen=50, truncating='post')  
  
    # Predicción de probabilidades  
    probabilities = self.model.predict(np.array(padded_sequence))  
    probability_for_class = probabilities[0]  
  
    return probability_for_class
```

Método `plot_training_history`:

- Genera gráficos de pérdida y precisión durante el entrenamiento y la validación.

```
def plot_training_history(self):  
    # Gráficos de pérdida  
    plt.plot(self.history.history['loss'], label='Entrenamiento')  
    plt.plot(self.history.history['val_loss'], label='Validación')  
    plt.title('Curva de Pérdida')  
    plt.xlabel('Épocas')  
    plt.ylabel('Pérdida')  
    plt.legend()  
    plt.show()  
  
    # Gráficos de precisión  
    plt.plot(self.history.history['accuracy'], label='Entrenamiento')  
    plt.plot(self.history.history['val_accuracy'], label='Validación')  
    plt.title('Curva de Precisión')  
    plt.xlabel('Épocas')  
    plt.ylabel('Precisión')  
    plt.legend()  
    plt.show()
```

Técnicas Utilizadas:

- Regularización L2 en algunas capas para prevenir el sobreajuste.
- Uso de Dropout para regularización durante el entrenamiento.
- Callbacks como **EarlyStopping** y **ModelCheckpoint** para mejorar el control del entrenamiento.



Clase CustomCallback

Método `on_epoch_end`:

- Este método se ejecuta al final de cada época durante el entrenamiento del modelo.
- Verifica si la precisión (accuracy) tanto en entrenamiento como en validación es mayor o igual al valor mínimo deseado (**`min_accuracy`**).
- Si se cumple la condición, imprime un mensaje indicando que se ha alcanzado el accuracy mínimo y detiene el entrenamiento (**`self.model.stop_training = True`**).

Uso del Callback:

- Este callback se integra con el entrenamiento del modelo y se activa al final de cada época.

```
from keras.callbacks import EarlyStopping
import tensorflow as tf

Comment Code
class CustomCallback(tf.keras.callbacks.Callback):
    def on_epoch_end(self, epoch, logs=None, min_accuracy=0.95):
        print("hola")
        # Verificar si se cumple la condición de precisión
        if logs['accuracy'] >= min_accuracy and logs['val_accuracy'] >= min_accuracy:
            print(f"Alcanzado el accuracy mínimo deseado ({min_accuracy}). Deteniendo el entrenamiento.")
            self.model.stop_training = True
```



Biblioteca Importada:

1. **ABC** y **abstractmethod** de **abc**: Importa la clase **ABC** (Abstract Base Class) y el decorador **abstractmethod** para crear una interfaz abstracta.

Clase TextClassificationModel (Interfaz Abstracta):

Método Abstracto **build_model**:

- Método que debe ser implementado por las clases concretas.
- Define la construcción del modelo de clasificación de texto, incluyendo la configuración de capas y parámetros.

Método Abstracto **train_model**:

- Método que debe ser implementado por las clases concretas.
- Define el entrenamiento del modelo utilizando datos de entrenamiento y etiquetas. Puede incluir configuraciones específicas del modelo, como número de épocas.

Método Abstracto **predict_probability**:

- Método que debe ser implementado por las clases concretas.
- Define la predicción de probabilidades para un texto dado. Este método puede ser utilizado para la clasificación de nuevos textos.

Método Abstracto **plot_training_history**:

- Método que debe ser implementado por las clases concretas.
- Define la generación de gráficos para visualizar la historia de entrenamiento del modelo, incluyendo pérdida y precisión a lo largo de las épocas.

```
from abc import ABC, abstractmethod

class TextClassificationModel(ABC):

    @abstractmethod
    def build_model(self):
        pass

    @abstractmethod
    def train_model(self, data_training, labels, epochs=20):
        pass

    @abstractmethod
    def predict_probability(self, text):
        pass

    @abstractmethod
    def plot_training_history(self):
        pass
```




Archivo main

- **Definición de Clases:**
 - **clases:** Lista que define las clases para la clasificación.
- **Inicialización del Modelo:**
 - **model:** Instancia de **TextClassificationModelImplements** con clases, un tokenizador y datos de instrucciones concatenados.
- **Construcción y Entrenamiento del Modelo:**
 - **model.build_model():** Construye el modelo de clasificación de texto.
 - **model.train_model(data_training, label_training, epochs=1000):** Entrena el modelo con datos y etiquetas especificadas.
- **Predicción y Visualización:**
 - **new_instruction:** Ejemplo de instrucción para predecir.
 - **model.predict_probability(new_instruction):** Predice probabilidades para la nueva instrucción.
 - **model.plot_training_history():** Visualiza la historia de entrenamiento.
- **Ejecución del Programa:**
 - **if __name__ == "__main__":** Ejecuta la función **main()** si el script es ejecutado directamente.

```
Click here to ask Blackbox to help you code faster |
from data.instructions_form import instructions_form
from data.instructions_browser import instructions_browser
from data.instructions_wait import instructions_wait
from data.instructions_not import instructions_not
from keras.preprocessing.text import Tokenizer
from text_classification_model_implements import TextClassificationModelImplements

Comment Code
def main():
    # Uso del modelo
    clas = [0, 1, 2, 3]
    model = TextClassificationModelImplements(clas, Tokenizer(), instructions_browser + instructions_form + instructions_wait + instructions_not)
    model.build_model()
    # Entrenamiento del modelo
    data_training = [instructions_browser, instructions_form, instructions_wait, instructions_not]
    label_training = [0, 1, 2, 3] # Las etiquetas deben coincidir con las clases definidas en clases
    model.train_model(data_training, label_training, epochs=1000) # Aumentar epochs

    # Ejemplo de predicción con el modelo
    new_instruction = "Ingresa los siguientes datos en el formulario: Modelo 'Samsung Galaxy Watch 4', Color 'Dorado', Almacenamiento '32GB', Navegación 'Navega hacia https://www.paginanueva.com usando Firefox'"
    probabilidades = model.predict_probability(new_instruction)
    print("Probabilidades predichas para cada clase:")
    print(probabilidades)
    model.plot_training_history()

    # "Ingresa los siguientes datos en el formulario: Modelo 'Samsung Galaxy Watch 4', Color 'Dorado', Almacenamiento '32GB', Navegación 'Navega hacia https://www.paginanueva.com usando Firefox'"
    # "Navega hacia https://www.paginanueva.com usando Firefox"
    # "Espera 4 segundos antes de proceder con la siguiente acción"

if __name__ == "__main__":
    main()
```



Ejecucion

El enunciado que se probara es "Ingresa los siguientes datos en el formulario: Modelo 'Samsung Galaxy Watch 4', Color 'Dorado', Almacenamiento '32GB', Precio '249.99 USD', Tienda 'GizmoHub'"

Deberia de clasificarse en el segunda clase con mas alto porcentaje de precision, ya que pertenece a instructions_form

```
data_training = [instructions_browser, instructions_form, instructions_wait, instructions_not]
```

Pare ejecutar se escribe python y el nombre o path del archivo

```
python /Users/hugocapuchino/Desktop/Tensorflow/main.py
```

```
<python /Users/hugocapuchino/Desktop/Tensorflow/main.py
Entrenamiento del Modelo:
Epoch 1/1000
/Users/hugocapuchino/Desktop/Tensorflow/venv/lib/python3.11/site-packages/keras/s
rc/engine/training.py:3103: UserWarning: You are saving your model as an HDF5 fil
e via `model.save()`. This file format is considered legacy. We recommend using i
nstead the native Keras format, e.g. `model.save('my_model.keras')`.
  saving_api.save_model(
5/5 - 2s - loss: 8.0550 - accuracy: 0.5725 - val_loss: 7.7483 - val_accuracy: 0.4
000 - 2s/epoch - 335ms/step
Epoch 2/1000
5/5 - 0s - loss: 6.8570 - accuracy: 0.8116 - val_loss: 7.0419 - val_accuracy: 0.7
833 - 254ms/epoch - 51ms/step
Epoch 3/1000
5/5 - 0s - loss: 5.8695 - accuracy: 0.9203 - val_loss: 6.4305 - val_accuracy: 0.8
667 - 255ms/epoch - 51ms/step
Epoch 4/1000
5/5 - 0s - loss: 5.1665 - accuracy: 0.9855 - val_loss: 5.8730 - val_accuracy: 1.0
000 - 282ms/epoch - 56ms/step
Epoch 5/1000
5/5 - 0s - loss: 4.5944 - accuracy: 1.0000 - val_loss: 5.3202 - val_accuracy: 1.0
000 - 266ms/epoch - 53ms/step
```

```
Probabilidades predichas para cada clase:
[0.01186326 0.95363873 0.01644472 0.01805333]
```

Se clasifico en la segunda clase con mayor porcentaje de precision



Informacion durante el entrenamiento.

